Documentación de Big Data Aplicado (BDA): ventas de farmacias europeas

1. Resumen

He montado una cadena completa de datos, de principio a fin:

Excel (Kaggle) → pandas (limpieza y agregación) → CSV → Node-RED (carga) → InfluxDB (series temporales) → Grafana (dashboards y alertas)

El objetivo es responder, con datos y gráficos, a tres preguntas de negocio:

1. ¿Qué países y categorías generan más ingresos y margen?
2. ¿Cómo evolucionan las ventas mes a mes?
3. ¿Cuál es el efecto de las promociones?

2. Los datos de partida

Usamos el dataset sintético *European Pharmacy Sales* (Kaggle, licencia MIT): un Excel con cuatro hojas organizadas en «estrella», es decir, una tabla de hechos (las ventas) rodeada de tablas de dimensiones (fecha, farmacia, producto).

Hoja	Contenido
FactSales	62.139 ventas (2024-2025)
DimDate	731 fechas
DimPharmacy	120 farmacias de 8 países
DimProduct	220 productos en 5 categorías

3. Entorno de trabajo

Componente	Dónde corre
InfluxDB 2.x	localhost:8086 (organización: somorrostro)
Grafana	localhost:3000
Node-RED	localhost:1880
Sistema	Windows con WSL2 (Ubuntu 24.04)

4. Manipulación y análisis de datos (40 %)

Tarea 1: cargar y transformar los datos con pandas

El notebook `Preparar_datos_influxdb.ipynb` hace lo siguiente, paso a paso:

1. **Carga** las cuatro hojas del Excel.
2. **Une** las ventas con las farmacias (para saber el país) y con los productos (para saber la categoría). Se usa `validate="many_to_one"` para que pandas avise si el cruce duplicara filas por error.
3. **Crea la columna Fecha** en UTC a partir de DateKey, porque InfluxDB trabaja con marcas de tiempo.
4. **Agrega** por Fecha, País, Categoría y PromoFlag, sumando ventas, unidades, ingresos, costes y margen.

¿Por qué agregar? En InfluxDB, un punto con el mismo measurement, los mismos tags y la misma marca de tiempo se **sobrescribe**. Sin agregar, perderíamos datos.

Resultado:

Fichero	Filas
ventas_diarias.csv	29.435
ventas_mensuales.csv	1.908

Comprobaciones de calidad: cero duplicados, cero nulos y totales idénticos a los del Excel original.



```
clave = ["Fecha"] + columnas_tag
print("Duplicados diario :", diario.duplicated(clave).sum())
print("Duplicados mensual:", mensual.duplicated(clave).sum())

print("Ingresos originales:", round(fact["RevenueEUR"].sum(), 2))
print("Ingresos diario    :", round(diario["ingresos_eur"].sum(), 2))
print("Ingresos mensual   :", round(mensual["ingresos_eur"].sum(), 2))

print("Nulos diario :", diario.isna().sum().sum())
print("Nulos mensual:", mensual.isna().sum().sum())
```

```
Duplicados diario : 0
Duplicados mensual: 0
Ingresos originales: 8633977.31
Ingresos diario    : 8633977.31
Ingresos mensual   : 8633977.31
Nulos diario : 0
Nulos mensual: 0
```

Por lo que mediante este proceso obtenemos dos csv necesarios para que Influxdb obtenga los datos.

Tarea 2: flujo de Node-RED para subir los datos

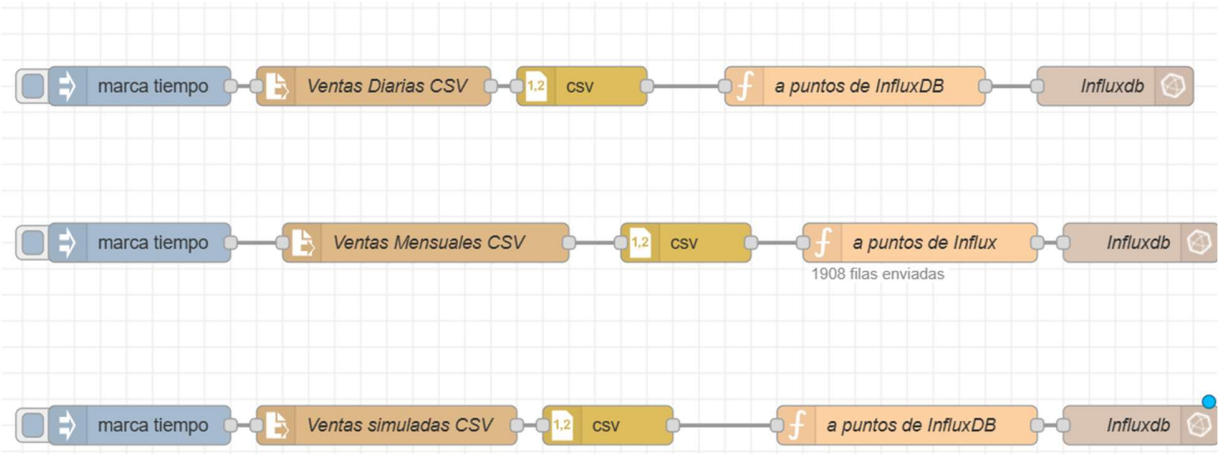
Node-RED es una herramienta visual que conecta nodos para mover y transformar datos; aquí lo usamos para cargar automáticamente los CSV de ventas en InfluxDB.

El flujo sigue esta cadena de nodos:

inject → file in → csv → function → influxdb batch

Nodo	Para qué sirve
inject	Arranca la carga con un clic
file in	Lee el CSV del disco
csv	Convierte cada línea en un objeto
function	Construye cada punto de InfluxDB: measurement `ventas`, tags (Country, Category, PromoFlag) como texto, fields numéricos y la fecha en milisegundos
influxdb batch	Envía todos los puntos de golpe

Nodos de Node-red:



Función “a puntos de influxDB”:

La función transforma cada fila del CSV en un punto de InfluxDB (measurement, tags, fields y timestamp) y los envía en lotes de 5.000 para una carga eficiente.

```
const rows = msg.payload;
const CHUNK = 5000;

for (let i = 0; i < rows.length; i += CHUNK) {
    const pts = rows.slice(i, i + CHUNK).map(r => {
        let f = String(r.Fecha).trim();
        if (f.includes(' ')) f = f.replace(' ', 'T');
        return {
            measurement: "ventas",
            tags: {
                Country: String(r.Country),
                Category: String(r.Category),
                PromoFlag: String(r.PromoFlag)
            },
            fields: {
                ventas: Number(r.ventas),
                unidades: Number(r.unidades),
                ingresos_eur: Number(r.ingresos_eur),
                costes_eur: Number(r.costes_eur),
                margen_eur: Number(r.margen_eur)
            },
            timestamp: new Date(f).getTime()
        };
    });
    node.send({ payload: pts });
}
node.status({ text: rows.length + " filas enviadas" });
return null;
```

Datos simulados de 2026 (para probar alertas)

Para poder comprobar que las alertas saltan, generamos datos de 2026. Se añadió estos datos falsos para poder implementar unas alertas que tuvieran sentido ya que en este proyecto no se contaba con una api con datos en tiempo real.

- Se copió 2025 sumando un año.
- Se añadió ruido gaussiano del 10 % (semilla 42, para que sea reproducible) y anomalías en el 2 % de las filas.
- El margen se recalculó.
- Resultado: 14.807 filas, del 2026-01-01 al 2026-12-31, cargadas **solo** en el bucket `ventas_diarias`.

Se añadieron datos simulados de 2026 al bucket ventas_diarias para poder probar las alertas. Los datos reales (2024-2025) no se tocan.

5. Gestión de series temporales con InfluxDB (30 %)

InfluxDB es una base de datos de series temporales; aquí almacena las ventas diarias y mensuales para que Grafana las consulte y las visualice.

Cómo está organizado

InfluxDB guarda los datos en capas, de mayor a menor:

Organización → Bucket → Measurement → Tags y Fields → Time

Concepto	Qué es	En nuestro proyecto
Organización	Espacio de trabajo	somorrostro
Bucket	«Base de datos» con su política de retención	ventas_diarias, ventas_mensuales
Measurement	Tipo de dato medido	ventas
Tag	Etiqueta **indexada** para filtrar rápido	Country, Category, PromoFlag
Field	Valor medido (no indexado)	ventas, unidades, ingresos_eur, costes_eur, margen_eur
Time	Marca de tiempo UTC	El día (o el primer día del mes en el bucket mensual)

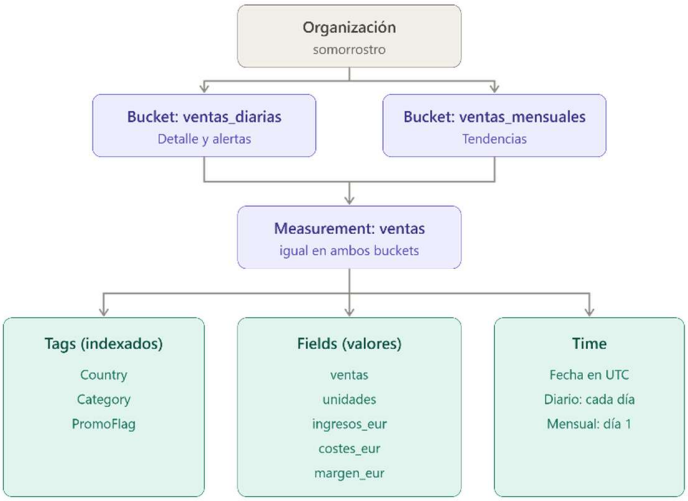
¿Por qué tags y fields así? Los tags son las columnas por las que filtramos y agrupamos (país, categoría, promoción), por eso van indexados. Los números que sumamos o promediamos son fields.

Buckets

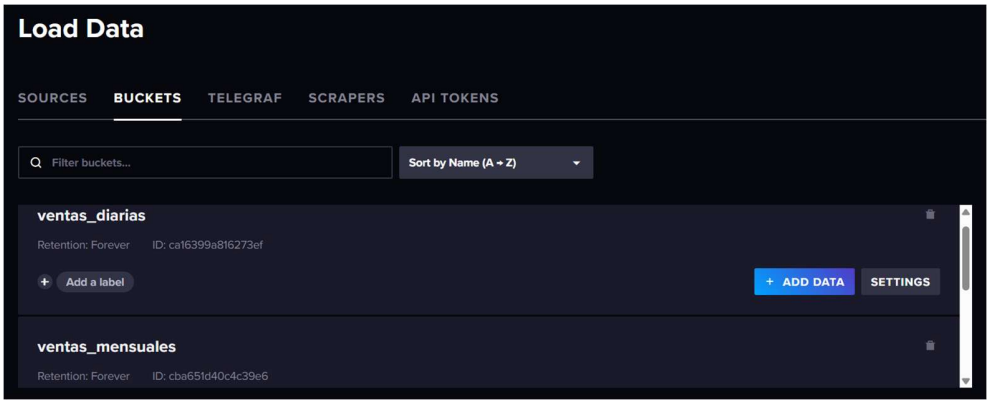
Bucket	Uso	

Bucket	Uso	
ventas_diarias	Detalle y alertas (incluye 2026 simulado)	
ventas_mensuales	Tendencias	

Organigrama de InfluxDB:



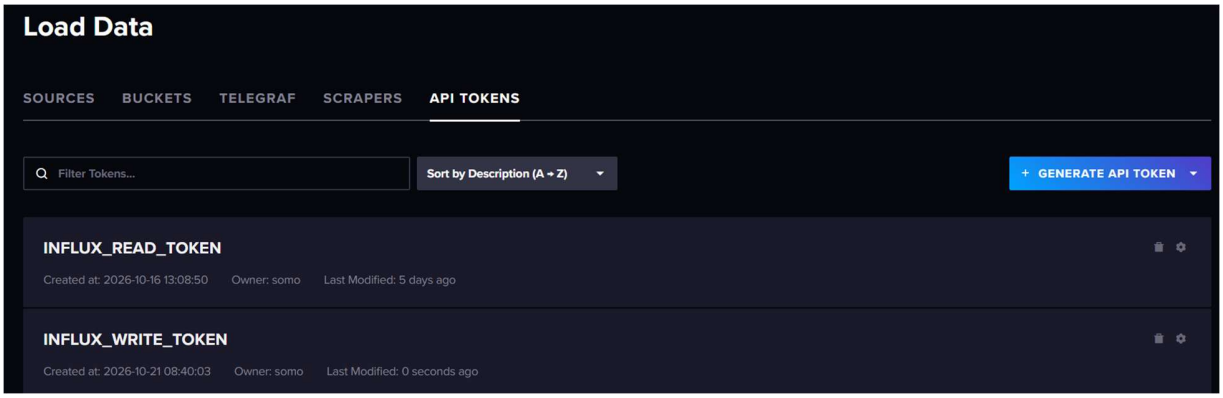
Buckets:



Tokens (seguridad)

Token	Permisos	Lo usa
Escritura	Solo escritura en los dos buckets	Node-RED
Lectura	Solo lectura en los dos buckets	Grafana

Usar un único token para todo es la peor práctica: si se filtra, da acceso total. Esta documentación no incluye ningún token ni contraseña.



6. Visualización y monitorización con Grafana (30 %)

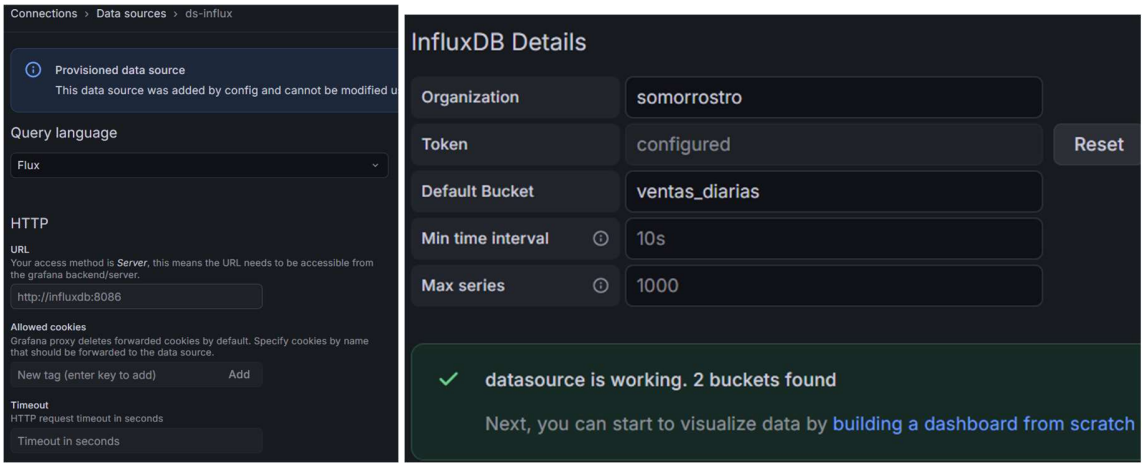
Grafana es una herramienta para **visualizar y vigilar datos**: se conecta a una base de datos (aquí InfluxDB), lee los datos con consultas y los muestra en gráficos dentro de paneles agrupados en *dashboards*. También puede **avisar con alertas** cuando un valor cruza un umbral.

Para qué la uso aquí:

- **Dashboards:** responder a las tres preguntas del reto (qué países y categorías rinden más, cómo evolucionan las ventas, qué efecto tienen las promociones) con barras, tarta, series temporales, gauges y tablas.
- **Alertas:** avisar cuando, por ejemplo, el margen en promoción baja del 20 % o los ingresos de un mes caen por debajo de 350.000 €.

Fuente de datos

La fuente de datos se llama `ds-influx`, usa el lenguaje **Flux** y la organización somorrostro. El margen porcentual se calcula en la propia consulta (`margen_eur / ingresos_eur`). Las consultas usan fechas absolutas (2024-01-01 a 2026-01-01) porque los datos son históricos.

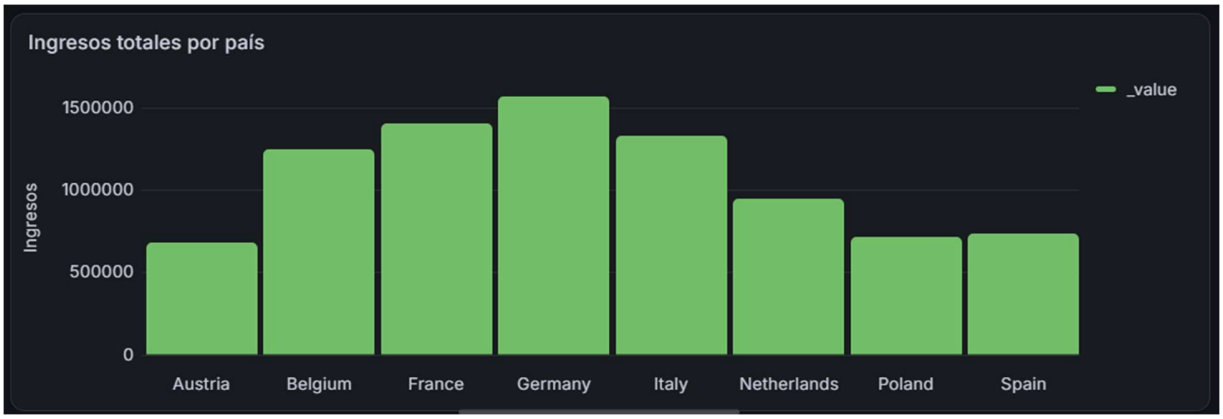


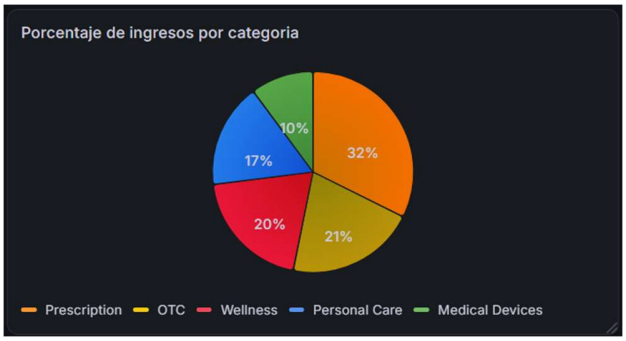
Tarea 1: dashboards

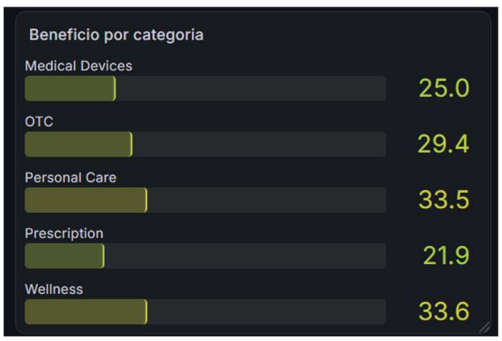
Se crearon **4 dashboards** para responder a las preguntas de negocio.

Dashboard	Pregunta	Paneles
1. Países y categorías	¿Qué países y categorías rinden más?	Bar chart de ingresos por país; pie chart de ingresos por categoría; bar gauge de margen % por categoría
2. Evolución mensual	¿Cómo evolucionan las ventas?	Time series; stat; table
3. Promociones	¿Qué efecto tienen las promociones?	Bar chart de margen % con y sin promoción; gauge de margen % en promoción
4.Rentabilidad y crecimiento de farmacias	¿Qué países y categorías crecen más, y cuánto margen se pierde por las promociones?	Bar chart Crecimiento de ingresos por país y categoría Bar gauge para el margen cedido por promociones, por categoría

Dashboard 1: Países y categorías







Qué responden los datos:

- **Países:** Alemania lidera en ingresos (1,568 M€) y Austria es el último (683 k€).

- **Categorías:** Wellness (33,6 %) y Personal Care (33,5 %) tienen los mejores márgenes, pero el prescription es el que más ingresos genera.

Dashboard 2: Evolución mensual



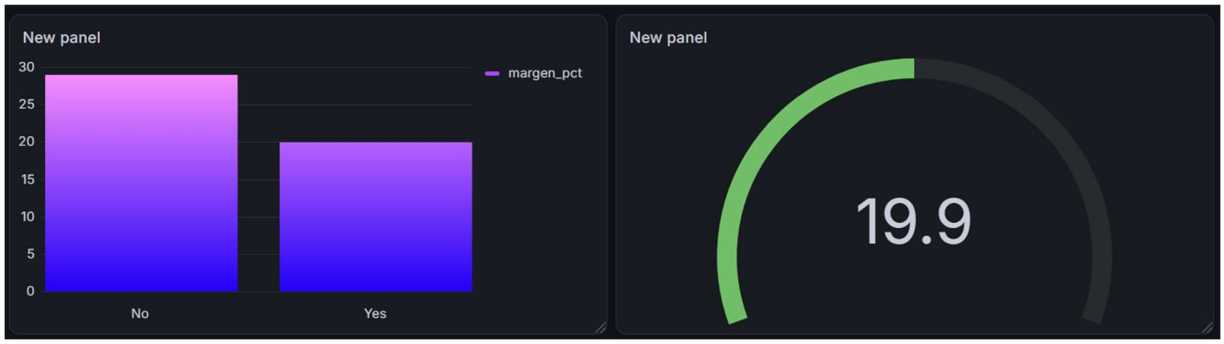
Tabla de ingresos mensuales 2024-2025

Time	Value
2024-02-01 01:00:00	348141
2024-03-01 01:00:00	327319
2024-04-01 02:00:00	346367
2024-05-01 02:00:00	330369
2024-06-01 02:00:00	357867
2024-07-01 02:00:00	342538

Qué responden los datos:

- **Evolución mensual:** los ingresos oscilan entre unos 330 k€ y 390 k€, sin una estacionalidad estable.

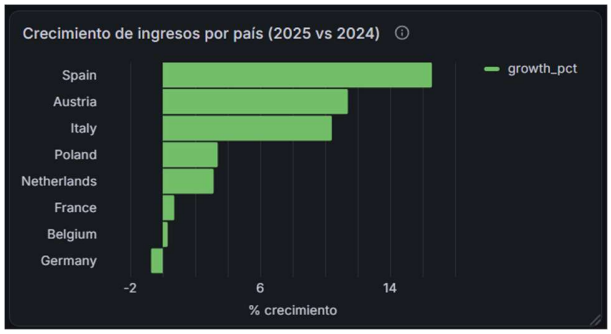
Dashboard 3: Promociones



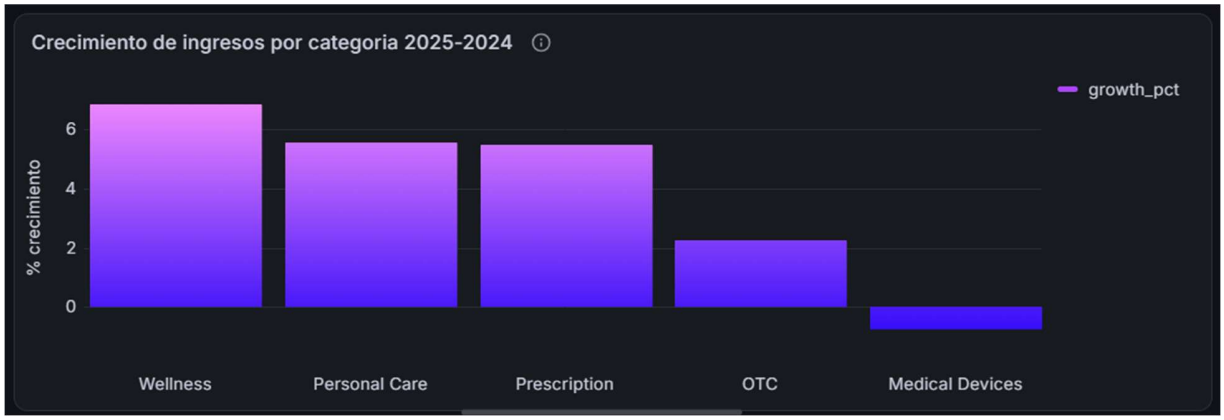
Qué responden los datos:

- **Promociones:** el margen es del 29,0 % sin promoción frente al 19,9 % con promoción. Es decir, vender con descuento reduce unos 9 puntos de margen.

Dashboard 4: Rentabilidad y crecimiento de farmacias







Qué responden los datos:

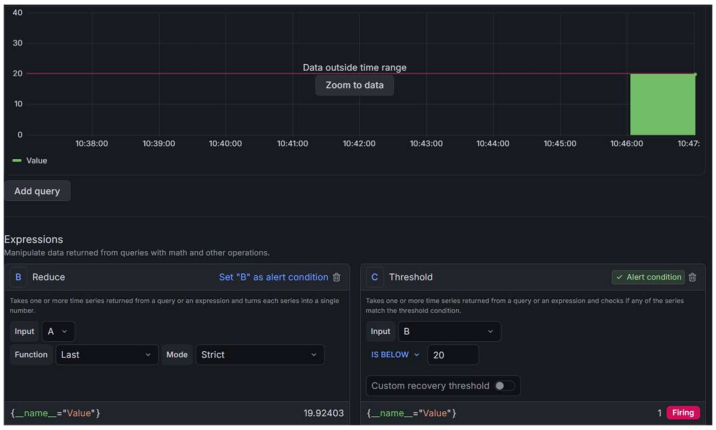
- **Países:** España lidera el crecimiento de ingresos (~16 %) y Alemania es el único país que baja.
- **Promociones:** Prescription es la categoría que más margen cede por vender con promoción.
- **Categorías:** Wellness crece más (~7 %) y Medical Device es la única que retrocede.

Tarea 2: alertas

Regla	Salta cuando	Valor actual	Estado
1. Margen % en promoción	< 20	~19,92	Firing
2. Ingresos mensual	“Mes anterior” (dinámico), < 350.000, **Normal**	~368.808€	Normal
3. Crecimiento de ingresos negativos por país	< 0 % (2025 vs 2024)	Alemania: −0,70 % (el resto, positivo)	Firing

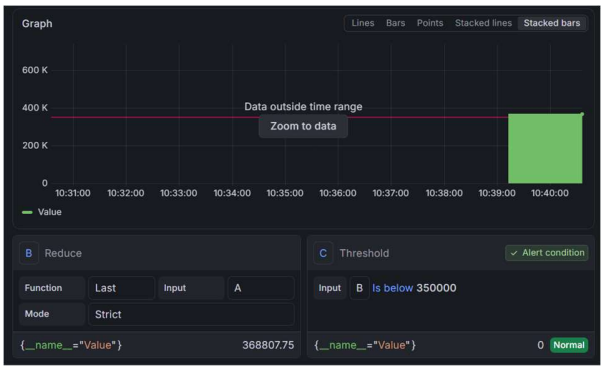
Regla 1: Margen % en promoción

Calcula el margen porcentual de las ventas en promoción: suma el margen y los ingresos de las filas con promoción entre 2024 y 2026, y divide margen entre ingresos por 100 para obtener un único porcentaje. La alerta salta si ese valor es menor que 20 (con ~19,92 % queda en Firing).



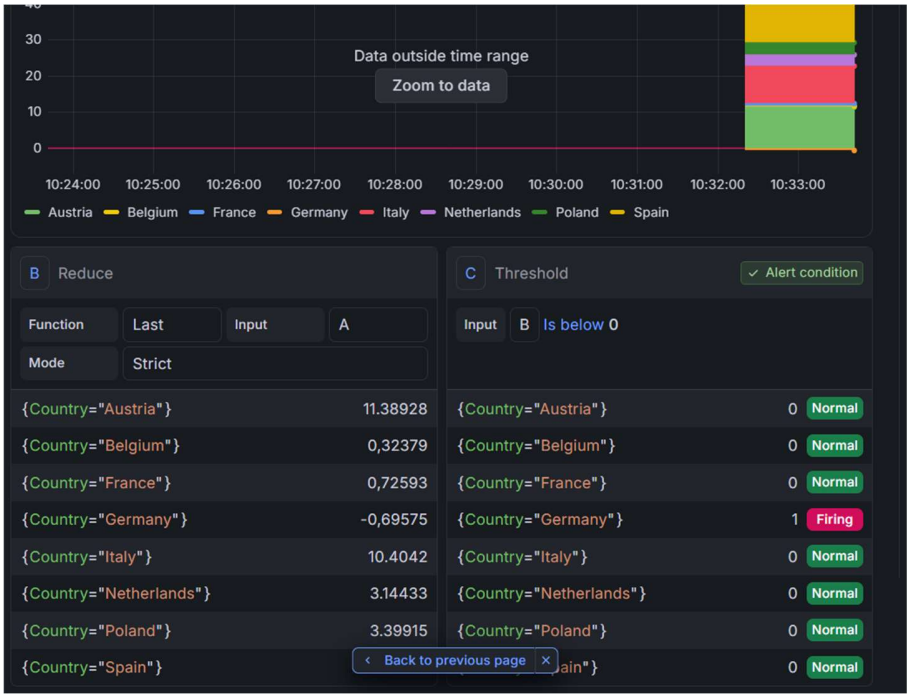
Regla 2: Ingreso mensual

Calcula las fechas automáticamente (hoy, 21 de octubre, toma del 1 de septiembre al 1 de octubre), suma todos los ingresos de ese periodo y los compara con 350.000 €. A diferencia del resto de consultas, que usan fechas absolutas porque los datos son históricos, esta es dinámica, así que su valor cambia cada mes.



Regla 3: Crecimiento de ingresos negativos por país

Devuelve una fila por país con su % de crecimiento 2025 vs 2024 y salta para cualquier país con valor menor que 0. Es una alerta multidimensional: Alemania (−0,70 %) está en Firing y los otros siete países, en Normal.



Contact point y notification policy

- **Contact point:** Aimar Mora, de tipo email. Es el destino de las tres alertas.
- **Notification policy:** política raíz que envía todo al contact point Aimar Mora, agrupando las alertas por grafana_folder y alertname.
- Las tres reglas usan ese mismo receptor en su notification_settings.