MODELOS DE IA

Propuesta de solución de inteligencia artificial para el retail farmacéutico europeo

Aimar Mora

Octubre de 2026

Índice

1. Descripción del problema y objetivo.....1
2. Principios y aplicaciones de IA en el sector.....1
3. Técnicas y modelos considerados.....1
4. Comparación con los datos del proyecto.....2
5. Modelo seleccionado y justificación.....2
6. Funcionamiento e impacto en la organización.....3
7. Limitaciones y riesgos.....3
Referencias.....3

1. Descripción del problema y objetivo

El cliente es una cadena de 120 farmacias en ocho países europeos que quiere decidir **en qué país, con qué categoría de producto y en qué momento vender para obtener el mayor beneficio**. Dispone de 62.139 ventas de 2024-2025 con unidades, ingresos, coste, margen y marca de promoción, unidas a tablas de farmacias, productos y calendario. No tiene datos de clientes, de stock ni de la competencia.

Objetivo de la IA: predecir **cuánto margen en euros generará cada categoría en cada país y mes**. Se predice por farmacia abierta, para comparar países de distinto tamaño, y se multiplica por las farmacias abiertas para obtener el margen total. Por ejemplo, responde a «¿cuánto margen dará Wellness en Bélgica en marzo de 2026?». Con las 40 previsiones de cada mes (8 países × 5 categorías) se ordena dónde conviene reforzar la venta. El modelo es útil si se equivoca menos que la media histórica y si las combinaciones que pone arriba generan más margen real que la media.

Salvo que se indique otra fuente, las cifras salen del análisis de los datos del cliente [1]. El análisis previo mostró que el margen por venta es parecido entre países (27,8-28,2 % de los ingresos), pero contando cada farmacia desde su apertura real, Polonia ingresa un 39 % menos por farmacia y mes que Bélgica; que Wellness y Personal Care tienen los mejores márgenes y Prescription el más bajo; que la estacionalidad no es estable (el mes de más margen fue julio en 2024 y mayo en 2025); y que las promociones no aumentan las unidades por venta y van asociadas a un margen menor (del 29,0 % al 19,9 %; la caída es parecida en todas las categorías, de 8,4 a 9,2 puntos). De los datos salen seis **requisitos**, cada uno con su evidencia:

ID	Requisito	Evidencia en los datos
R1	Predecir un número	Se quiere el margen en euros
R2	Datos tabulares mixtos	País y categoría (texto); nº, tipo y tamaño de farmacias abiertas y % de promoción (números)
R3	Funcionar con pocos datos	Solo 480 filas para entrenar (40 combinaciones × 12 meses de 2024)
R4	Ser estable con datos nuevos	En 2025 abren farmacias en Austria, Alemania, Italia y España: la previsión no debe dispararse con valores que el modelo no vio
R5	No fijar una estacionalidad	El mes pico cambia de un año a otro (correlación entre años: 0,46)
R6	Ser explicable	El equipo comercial debe justificar sus decisiones

Tabla 1. Requisitos del problema

2. Principios y aplicaciones de IA en el sector

Un sistema de IA es un agente que percibe su entorno y actúa para lograr un objetivo [2]. En el aprendizaje automático ese comportamiento no se programa con reglas: se aprende de ejemplos, ajustando el modelo para que cometa el menor error posible. La solución usa aprendizaje automático **supervisado**: aprende de ventas pasadas cuyo margen ya se conoce y busca una regla que acierte también en meses que no ha visto (generalizar). Todo proyecto de IA sigue el mismo ciclo: entender el negocio y los datos, preparar las variables, entrenar, evaluar con datos nuevos y desplegar [3]. Este documento sigue ese orden.

Dos principios guían la elección del modelo. **Sesgo y varianza** [4]: un modelo demasiado simple no capta la relación real (sesgo) y uno demasiado flexible memoriza el ruido de pocos datos (varianza o sobreajuste); el punto óptimo depende de cuántos datos haya. **No existe un algoritmo mejor para todo** [5]: la teoría solo preselecciona candidatos y la decisión se toma comparándolos con los datos del cliente (sección 4).

El no supervisado (agrupar farmacias) no predice el margen, y el de refuerzo exigiría experimentar con promociones reales. Los sistemas de reglas se usan solo como control (precios regulados de Prescription) y la automatización para la carga mensual; la lógica difusa y la visión artificial no encajan (el margen es un número preciso y no hay imágenes).

Aplicación	Problema y beneficio	Técnica	Qué aporta a este proyecto
Walgreens (Zebra) [6]	Prever la demanda en más de 8.000 farmacias con más de 50 variables; sobreprevisión del 15 % al 1 % según el proveedor	ML con ventas y datos externos	La mejora viene de las variables externas; el cliente no las tiene, así que no se prometen mejoras así
Fabricantes farmacéuticos (Zhu et al.) [7]	Prever la demanda de productos con poco historial	ML entrenado con muchas series a la vez	Con pocos datos, mejor un solo modelo para todas las combinaciones; el stock sería la primera variable a añadir
Walmart, competición M5 [8, 9]	Prever 42.840 series de ventas de un gran minorista	Ganó gradient boosting (LightGBM)	Los árboles son la referencia en retail, pero con miles de series; con 480 filas hay que comprobarlo (sección 4)
Gran consumo (Henzel y Sikora) [10]	Prever la eficacia de cada promoción antes de lanzarla	Gradient boosting	Usar la promoción como variable y probarla antes de extenderla (piloto)

Tabla 2. Aplicaciones de IA en retail y farmacia, y qué aporta cada una

En resumen, la investigación fija tres decisiones: modelos de árboles como candidatos principales, un solo modelo para todas las combinaciones y comparación obligatoria con los datos del cliente.

3. Técnicas y modelos considerados

El problema es de **regresión supervisada**: predecir un número (el margen) con datos tabulares y una componente temporal. La regresión lineal y las series temporales tienen capacidades opuestas: la regresión usa variables explicativas (país, categoría, promoción) pero no recuerda el pasado; la serie temporal recuerda el pasado pero no usa variables, así que no puede responder «¿qué pasa si cambio la promoción?».

Tres de los modelos se basan en **árboles de decisión**. Un árbol divide los datos con preguntas sucesivas («¿categoría = Wellness?», «¿país = Polonia?») y en cada paso elige la pregunta que más reduce el error. Así capta combinaciones sin indicarlas y nunca predice fuera del rango que ha visto. Un árbol solo es inestable, por eso se combinan: **Random Forest** promedia muchos árboles independientes y **reduce la varianza**; **Gradient Boosting** encadena árboles que corrigen errores y **reduce el sesgo**.

Modelo	Cómo funciona	Ventaja y límite en este problema
Regresión lineal	Suma un efecto fijo por variable: margen = $b_0 + b_1 \cdot x_1 + b_2 \cdot x_2 + \ldots$	Explicable, pero extrapola: las variables de farmacias casi no cambian dentro de cada país en 2024, reciben pesos grandes y, al abrir farmacias en 2025, la previsión se dispara (R4)
Series temporales (ARIMA, Holt)	Predicen cada combinación solo con su propio pasado: nivel, tendencia y estacionalidad	Estimar la estacionalidad exige al menos dos ciclos completos [11] y, entrenando con 2024, solo hay uno (R5)
Random Forest [12]	Entrena 500 árboles, cada uno con una muestra al azar de filas y variables, y promedia sus resultados	Estable con pocos datos (R3) y no extrapola (R4); puede quedarse corto si hubiera mucha señal por captar
Gradient Boosting [13]	Empieza con la media y añade árboles pequeños de uno en uno: cada árbol predice el error que queda y se suma con un peso pequeño ($F_1 = F_0 + 0{,}05 \cdot \text{árbol}_1$, y así sucesivamente). Se controla con el nº de árboles (300), su profundidad (3) y ese peso	Suele ser el más preciso en datos tabulares [14], pero depende de sus ajustes y puede sobreajustar con pocos datos (R3)
Red neuronal (LSTM) [15]	Lee la serie mes a mes. En cada mes combina el dato nuevo con lo que recuerda, y tres puertas deciden qué olvidar, qué guardar y qué usar para predecir; así recuerda lo ocurrido muchos meses atrás	Solo habría 40 series de 12 meses. La red probada (MLP) tiene 1.153 parámetros para 480 filas: más parámetros que ejemplos (R3). Poco explicable (R6)

Tabla 3. Cómo funciona cada técnica y cómo encaja en el problema

4. Comparación con los datos del proyecto

Los modelos se entrenaron con 2024 y se evaluaron con 2025, que no habían visto (prueba A), y se repitió entrenando hasta junio de 2025 y evaluando julio-diciembre (prueba B). Se mide el error medio en euros por farmacia y mes (MAE; la media real en 2025 es 177 €). Una LSTM no puede entrenarse con 12 puntos por serie, así que la red neuronal se probó como perceptrón multicapa (MLP) con las mismas variables [1].

Modelo	MAE A (€)	MAE B (€)	Margen real del 20 % mejor clasificado (A)	Correlación del ranking (A)
Media histórica (referencia)	27,4	25,9	238 €	0,81
Regresión lineal	38,9	27,5	217 €	0,68
Serie temporal (Holt)	44,7	31,8	232 €	0,62
Random Forest	**27,4**	**25,9**	**244 €**	**0,83**
Gradient Boosting	27,8	27,0	240 €	0,81
Red neuronal (MLP)	28,8	29,1	240 €	0,81

Tabla 4. Resultados con los datos reales (MAE: error medio; cuanto menor, mejor)

Lectura. La serie temporal es la peor, como se esperaba (R5). La regresión lineal falla en la prueba A por extrapolar: solo con país y categoría su error es de 27,5 €, y al añadir las variables de farmacias sube a 38,9 € (R4). **Gradient Boosting no mejora a la referencia** en ninguna prueba, ni después de ajustarlo con datos de 2024 (27,7 €), y varía más según la semilla aleatoria (27,8-28,2 € frente a 27,2-27,4 € de Random Forest). El motivo: país y categoría explican el 74 % de la variación y el mes y la promoción casi nada. Hay poca señal que corregir, así que lo importante es no sobreajustar, que es lo que mejor hace Random Forest.

5. Modelo seleccionado y justificación

Se propone **Random Forest aplicado a regresión**, en lugar del Gradient Boosting planteado al principio, con la media histórica como mínimo que debe igualar. Es adecuado porque:

- **Es el mejor o empata en las dos pruebas** y el que mejor ordena: las combinaciones que pone en el 20 % superior tuvieron en 2025 un margen real de 244 € por farmacia y mes, un 38 % más que la media.
- **Es estable:** reduce la varianza con pocos datos (R3), no se dispara con farmacias nuevas (R4) y trata el mes como una variable más y no como un patrón fijo (R5).
- **Puede crecer:** a diferencia de la media histórica, admite variables nuevas (stock, precios, competencia), y la importancia de cada variable permite explicar el ranking (R6).

Del margen por farmacia al beneficio total. Margen total = margen previsto por farmacia × farmacias abiertas, sumado en todas las combinaciones. Ejemplo: Wellness en Bélgica en marzo de 2025: 232,9 € × 14 farmacias = 3.261 € previstos (reales: 4.025 €). Sumando las 480 previsiones de 2025 salen 1.242.252 €, frente a 1.239.676 € reales (+0,2 %), y el error medio en el total de cada mes es del 3,1 %. Es margen bruto (ingresos − coste del producto), no beneficio neto, porque no hay datos de alquiler ni de personal.

Validación y causalidad. Acertar en 2025 prueba que el modelo **predice** bien, no que seguir sus recomendaciones **aumente** el margen. Del mismo modo, que las promociones vayan con menos margen no prueba que retirarlas lo suba: se reparten igual en todas las categorías (12 % de las ventas), así que la caída viene del descuento, pero no se sabe si atraen clientes a la farmacia. Por eso se hace un **piloto de 3 meses**: en cada país, la mitad de las farmacias, elegidas al azar, sigue el ranking y la otra mitad trabaja como hoy (grupo de control). Se compara cuánto

cambia el margen por farmacia de cada grupo frente al mismo trimestre del año anterior (diferencia en diferencias), y solo si el primer grupo mejora se extiende a toda la cadena.

6. Funcionamiento e impacto en la organización

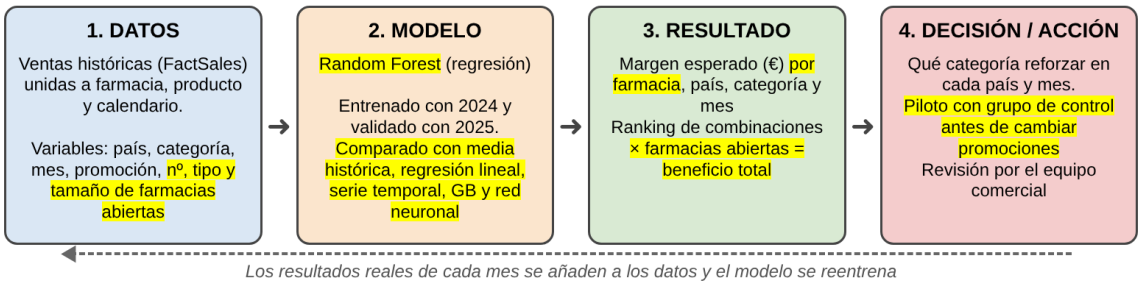


Figura 1. Diagrama de la solución propuesta

Cada mes se cargan automáticamente las ventas reales, el modelo se reentrena porque los hábitos cambian, y se genera un ranking en euros por farmacia y mes. El equipo comercial lo revisa con las reglas de control y decide si aplicarlo: la IA apoya la decisión, no la sustituye. Cambia tres cosas:

- **Qué priorizar:** un ranking de las 40 combinaciones cada mes en lugar de informes descriptivos, que ahorra tiempo al equipo comercial.
- **Qué promociones revisar:** las asociadas a 9,1 puntos menos de margen, comprobándolo antes en el piloto.
- **Cómo se evalúa:** se pasa de describir el pasado a comparar cada mes lo previsto con lo real y con el grupo de control.

7. Limitaciones y riesgos

- **Poca ventaja sobre la referencia:** con datos sintéticos de dos años el modelo apenas mejora a la media y el mes aporta poco (el «cuándo» es lo menos fiable). Su valor hoy está en ordenar y automatizar; la ventaja debe confirmarse con datos reales y más variables (stock, clientes, competencia).
- **Decisiones sin supervisión:** Prescription tiene el margen porcentual más bajo pero el mayor margen en euros por farmacia (224 € al mes); priorizar solo el porcentaje lo descuidaría. Se mitiga con reglas y revisión humana.
- **Sobreajuste y pérdida de vigencia:** se mitigan validando con meses posteriores, reentrenando cada mes y vigilando que el error no supere al de la referencia. **Privacidad:** los datos actuales no son personales; si se añadieran datos de clientes habría que cumplir el RGPD.

Referencias

[1] Datos del cliente (Pharmacy_data.xlsx: 62.139 ventas de 2024-2025) y análisis propio con el script validacion_modelos.py (pandas y scikit-learn), adjunto al trabajo.
[2] Russell, S. y Norvig, P. (2021). Artificial Intelligence: A Modern Approach (4.ª ed.). Pearson.
[3] Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. y Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc.
[4] Hastie, T., Tibshirani, R. y Friedman, J. (2009). The Elements of Statistical Learning (2.ª ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7
[5] Wolpert, D. H. (1996). The lack of a priori distinctions between learning algorithms. Neural Computation, 8(7), 1341-1390. https://doi.org/10.1162/neco.1996.8.7.1341
[6] Zebra Technologies (2025). Walgreens leverages Zebra's AI-powered demand forecasting to thrive in volatile markets [caso de éxito del proveedor]. https://www.zebra.com/ap/en/resource-library/success-stories/walgreens-leverages-zebras-ai-powered-demand-forecasting-to-thrive-in-volatile-markets.html (consultado el 26/10/2026).
[7] Zhu, X., Ninh, A., Zhao, H. y Liu, Z. (2021). Demand forecasting with supply-chain information and machine learning: evidence in the pharmaceutical industry. Production and Operations Management, 30(9), 3231-3252. https://doi.org/10.1111/poms.13426
[8] Makridakis, S., Spiliotis, E. y Assimakopoulos, V. (2022). M5 accuracy competition: results, findings, and conclusions. International Journal of Forecasting, 38(4), 1346-1364. https://doi.org/10.1016/j.ijforecast.2021.11.013
[9] Makridakis, S., Petropoulos, F. y Spiliotis, E. (2022). Introduction to the M5 forecasting competition special issue. International Journal of Forecasting, 38(4), 1279-1282.
[10] Henzel, J. y Sikora, M. (2020). Gradient boosting application in forecasting of performance indicators values for measuring the efficiency of promotions in FMCG retail. FedCSIS 2020. https://arxiv.org/abs/2006.04945
[11] Hyndman, R. J. (14 de julio de 2018). Seasonal decomposition of short time series [entrada de blog]. https://www.r-bloggers.com/2018/07/seasonal-decomposition-of-short-time-series/ (consultado el 26/10/2026).
[12] Breiman, L. (2001). Random forests. Machine Learning, 45, 5-32. https://doi.org/10.1023/A:1010933404324
[13] Friedman, J. H. (2001). Greedy function approximation: a gradient boosting machine. Annals of Statistics, 29(5), 1189-1232. https://doi.org/10.1214/aos/1013203451
[14] Grinsztajn, L., Oyallon, E. y Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? NeurIPS 35. https://arxiv.org/abs/2207.08815
[15] Hochreiter, S. y Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), 1735-1780. https://doi.org/10.1162/neco.1997.9.8.1735